

均匀覆盖

128 个专家 × 4 行

共 512 次分派



理想权重读取



4.5 GiB

$128 \times 36 \text{ MiB}$

集中到同八个专家

8 个专家 × 64 行

共 512 次分派



288 MiB

$8 \times 36 \text{ MiB}$