



多卡协作：一个实例共同处理一批请求




完整副本：分别接收独立请求



PD：按生成阶段分工



AF：按层内算子分工



不同阶段可分别排队、组成批次

同一请求每层都经过两侧计算