

缩进层级决定保存到何时

遍历输出块 io、jo

创建 FP32 累加器：16 KiB



循环 ko：共 128 次

读取 A、W 块 → 更新累加器



归约结束 → BF16 舍入 → SiLU