

平均每个输出 token 的耗时 / ms

