

第一部分 模型与负载

1 初识 AI Infra

2 模型架构

3 推理与训练负载



第二部分 芯片与系统

4 加速器架构

5 算子与运行时

6 超节点

7 数据中心网络



第三部分 推理与训练系统

8 推理优化

9 分布式推理

10 训练系统

11 资源调度与运行环境

12 端边云协同