


路径一：先展开每个上下文 token



上下文先计算 $K = c U_k$

路径二：先变换当前查询



查询先计算 $q U_k^T$