

提示 token → 编码器 20 层

编码器末层表示
投影为全局 KV

全局 KV 供解码器读取

提示末尾 ≤ 128 token
取编码器输出

解码器 20 层重放
构建局部 SWA

生成新 token: 编码器 → 解码器 → 输出

