

从空状态处理 8K 输入

普通全层：8,192 token $\times$ 40 层

CED 编码器
8,192 token $\times$ 20 层

局部重放
128 $\times$ 20

327,680 $\rightarrow$ 166,400 token 层

另计：全局 KV 投影、注意力及其他工作

生成阶段仍执行完整 40 层主干