

图像编码为视觉 token，再输入语言模型

