


图像编码为视觉 token，再输入语言模型

640×640 像素图像



```
graph TD; A[640 x 640 像素图像] --> B[16 x 16 像素一块 -> 40 x 40 个块]; B --> C[相邻 2 x 2 块合并 -> 20 x 20 个 token];
```

16×16 像素一块 $\rightarrow$ 40×40 个块

相邻 2×2 块合并 $\rightarrow$ 20×20 个 token