

图像先成为位置，再成为语言模型输入

640×640 像素图像

```
graph TD; A[640 x 640 像素图像] --> B[16 x 16 像素一块 -> 40 x 40 个块]; B --> C[相邻 2 x 2 块合并 -> 20 x 20 个位置];
```

16×16 像素一块 $\rightarrow$ 40×40 个块

相邻 2×2 块合并 $\rightarrow$ 20×20 个位置