

400 个视觉 token，各对应一个特征向量

四组视觉特征：每组宽 2560



编码结果： $400 \times 4 \times 2560 \times 2$ bytes



进入语言主干后，另产生各层 KV