


QK → Softmax → PV: 两次交接



94 GB/s 时占用接口约 2.79 μ s

CV: 64 KiB + 64 KiB



要在 1.024 μ s 内交接, CV 需 128 GB/s

外层接口释放 256 KiB; 直接通路承担 128 KiB