

## 保存低位宽中间结果

读原输入 32 + 写量化 16 + 重读 192

输入相关：240 MiB

## 每个列块重新量化

读原输入求 scale 32 + 重读原输入 384

输入相关：416 MiB