

注意力与路由器：每卡处理自己持有的 token



All-to-All 派发：按所选专家的所在卡发送输入



卡 0

E0

E1

E2

E3



卡 1

E4

E5

E6

E7



All-to-All 返回：结果回到 token 所在卡，按路由权重合并

