


注意力子层：按头切分，输出投影产生部分和



FFN 子层：按中间维切分，下投影产生部分和

