

原始请求：8192 输入，129 输出



8 请求/s

命中 6144 个前缀位置



9 请求/s

输出增至 1025 个 token



约 1.19 请求/s

蓝色：prefill    绿色：decode