

已可靠记录的序列

输入 8192 token

输出 1—128

输出 129

故障前保存的 KV

输入 8192 token

生成部分尚未保存

恢复后继续生成

输入 8192 token

输出 1—128

输出 129

补算 128 token $\rightarrow$ KV 到 8320 $\rightarrow$ 处理输出 129