

已返回并记录的序列

输入：8192 个位置

已返回输出 1—128

输出 129

故障前保存的 KV

输入：8192 个位置

缺少生成部分的 KV

重建后继续生成

将已记录的输出 1—128 重新送入模型

输入：8192 个位置

已返回输出 1—128

输出 129

KV 先恢复到 8320 个位置，再处理输出 129，生成下一个 token。