

传输开始：两端都占用完整空间

Qwen3-8B, GQA



DeepSeek-V3, 紧凑 MLA



数据复制中；方框宽度按字节数比例