

μ : 实际生成样本的策略



π_{old} : 本轮优化开始时的策略



π_{θ} : 本轮更新中的当前策略

对同一前缀与 token 分别记录概率