

图片：0.8 MB

重做视觉编码
再处理语言前缀

编码缓存 EC：7.8 MiB

从语言前缀处理开始

视觉 token KV：56.3 MiB

从匹配前缀之后继续